Практические занятия по анализу главных компонент (PCA)

Методическое пособие (фрагмент)

Содержание

1 Введение **2**

2 Нотация и основные определения **2**

3 Практика 1. Разведочный анализ данных (EDA) **3**

3.1 Цели и задачи 3

3.2 Пример: набор данных Iris 3

3.3 Упражнение 1 (Iris, корреляции) 3

3.4 Упражнение 2 (собственный датасет) 4

4 Практика 2. Реализация PCA “с нуля” и сравнение со sklearn **4**

4.1 Цели 4

4.2 Упражнение 3 (малый 2D пример) 5

4.3 Упражнение 4 (PCA на Iris: NumPy vs sklearn) 5

5 Практика 3. Объяснённая дисперсия и biplot **5**

5.1 Explained variance и выбор числа компонент 5

5.2 Упражнение 5 (выбор k для Iris) 6

5.3 Biplot и интерпретация компонент 6

5.4 Упражнение 6 (biplot для Iris) 6

6 Практика 4. PCA и кластеризация **6**

6.1 PCA как шаг перед k–means 6

6.2 Упражнение 7 (Iris: PCA + k–means) 7

6.3 Упражнение 8 (реальный многомерный датасет) 7

1 Введение

Данное пособие посвящено методике проведения первых четырёх практических занятий по курсу *Анализ главных компонент (PCA, Principal Component Analysis)* для магистрантов направления “Анализ больших данных, нейросети, ИИ”.

Цель практик — сформировать у студентов:

- интуитивное понимание того, зачем нужен PCA в задачах анализа данных,
- уверенные навыки реализации PCA в среде Python (NumPy, scikit–learn),
- умение выбирать число главных компонент, интерпретировать их через biplot,
- понимание роли PCA как шага предварительного снижения размерности перед кластеризацией и другими методами.

Все упражнения сопровождаются решениями или подробными набросками решений, что позволяет использовать данный текст как основу для самостоятельной работы и подготовки к научным проектам и публикациям.

2 Нотация и основные определения

Пусть $X \in \mathbb{R}^{n\times p}$ — матрица данных, где n — число наблюдений (объектов), p — число признаков. Строки $x_i^\top$ являются векторами признаков отдельных объектов.

Центрирование данных. Обозначим среднее значение по j–му признаку через

$$\bar{X}_{\cdot j} = \frac{1}{n}\sum_{i=1}^{n} X_{ij}.$$

Тогда центрированные данные $\tilde{X}$ вводятся как

$$\tilde{X}_{ij} = X_{ij} - \bar{X}_{\cdot j}.$$

Ковариационная матрица. Матрица ковариации признаков определяется как

$$S = \frac{1}{n-1}\tilde{X}^\top \tilde{X} \in \mathbb{R}^{p\times p}.$$

Собственные значения и собственные векторы. Пусть

$$Sw_k = \lambda_k w_k, \quad \lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_p.$$

Векторы w_k называются *главными направлениями* (loadings), а скалярные значения λ_k — соответствующими дисперсиями главных компонент.

Главные компоненты (scores). Координаты наблюдений в пространстве главных компонент задаются матрицей

$$Z = \tilde{X}W, \quad W = [w_1, \ldots, w_p] \in \mathbb{R}^{p \times p}.$$

Столбцы z_k матрицы Z называются главными компонентами (scores).

Доля объяснённой дисперсии. Для первых k компонент доля объяснённой дисперсии определяется как

$$\mathrm{EVR}_k = \frac{\sum_{i=1}^{k} \lambda_i}{\sum_{i=1}^{p} \lambda_i}.$$

3 Практика 1. Разведочный анализ данных (EDA)

3.1 Цели и задачи

Практика 1 направлена на формирование у студентов навыков первичного знакомство с данными:

- получение описательных статистик;
- анализ корреляций между признаками;
- формулирование гипотез о возможных “главных направлениях” вариации.

3.2 Пример: набор данных Iris

Рассматривается классический набор Iris, включающий 150 наблюдений и 4 числовых признака:

- длина чашелистика (sepal length),
- ширина чашелистика (sepal width),
- длина лепестка (petal length),
- ширина лепестка (petal width),

а также категориальный признак — вид ириса (3 класса).

3.3 Упражнение 1 (Iris, корреляции)

Задание. Для набора Iris:

1. вычислите описательные статистики по каждому признаку;
2. постройте матрицу корреляций;
3. укажите пару признаков с наибольшей по модулю корреляцией;

4. объясните, почему PCA, вероятнее всего, объединит эти признаки в первую главную компоненту.

Набросок решения. В среде Python:

```
from sklearn.datasets import load_iris
import pandas as pd

iris = load_iris()
X = iris.data
feature_names = iris.feature_names

df = pd.DataFrame(X, columns=feature_names)
print(df.describe())
print(df.corr())
```

Как правило, максимальная корреляция наблюдается между признаками длины и ширины лепестка. В пространстве этих признаков точки расположены вдоль вытянутого эллипса; первая главная компонента ориентируется вдоль этого эллипса, объединяя вариацию двух признаков.

3.4 Упражнение 2 (собственный датасет)

Задание. Выберите небольшой табличный датасет (4–10 числовых признаков), например, из репозиториев Kaggle или UCI. Выполните:

1. расчёт описательных статистик;
2. построение матрицы корреляций и диаграмм рассеяния;
3. формулировку гипотез о возможных главных компонентах (например, “общий размер”, “уровень активности”).

Комментарий. Эти гипотезы позже будут проверяться с помощью PCA, что создаёт связку между интуитивным EDA и строгим спектральным анализом.

4 Практика 2. Реализация PCA “с нуля” и сравнение со sklearn

4.1 Цели

- Реализовать этапы PCA на уровне линейной алгебры.
- Понять связь между формальным определением и реализацией в `scikit-learn`.

4.2 Упражнение 3 (малый 2D пример)

Задание. Рассмотрите три точки в $\mathbb{R}^2$:

$$x_1 = (1, 2), \quad x_2 = (2, 3), \quad x_3 = (3, 4).$$

Выполните вручную:

1. центрирование данных;
2. вычисление ковариационной матрицы;
3. поиск собственных значений и собственных векторов;
4. определение направления первой главной компоненты.

Решение. См. подробный разбор в основном тексте (центры, ковариация, собственные значения). Первая главная компонента совпадает (с точностью до масштаба) с вектором $(1, 1)$.

4.3 Упражнение 4 (PCA на Iris: NumPy vs sklearn)

Задание. Реализуйте PCA на Iris вручную и сравните с `sklearn.decomposition.PCA`:

1. вычислите $S = \frac{1}{n-1}\tilde{X}^\top \tilde{X}$ и его спектр;
2. постройте первые две компоненты Z_{manual};
3. сравните Z_{manual} с результатом `PCA(n_components=2)` по корреляции столбцов.

Набросок кода приведён в соответствующем Colab–шаблоне.

5 Практика 3. Объяснённая дисперсия и biplot

5.1 Explained variance и выбор числа компонент

На практике 3 рассматривается выбор числа компонент на основе доли объяснённой дисперсии:

$$\mathrm{EVR}_k = \frac{\sum_{i=1}^{k} \lambda_i}{\sum_{i=1}^{p} \lambda_i}.$$

Студенты строят scree–plot (график собственных значений) и график cumulative EVR, выбирая минимальное k, обеспечивающее требуемый порог (например, 95%).

5.2 Упражнение 5 (выбор k для Iris)

Задание. На основе cumulative EVR для Iris:

1. найдите минимальное k при EVR ≥ 0.90;
2. найдите минимальное k при EVR ≥ 0.95;
3. сопоставьте результаты с формой scree–plot.

Комментарий. Для Iris обычно двух компонент уже достаточно, что мотивирует дальнейшее использование плоскости $(\mathrm{PC1}, \mathrm{PC2})$ как основного пространства для визуализации.

5.3 Biplot и интерпретация компонент

Biplot позволяет одновременно отображать:

- точки–наблюдения в координатах первых компонент (scores);
- векторы признаков в том же пространстве (loadings).

По направлению и длине векторов признаков можно судить об их вкладе в компоненты и взаимных корреляциях.

5.4 Упражнение 6 (biplot для Iris)

Задание. Постройте biplot для первых двух компонент на Iris и ответьте:

1. какие признаки формируют первую и вторую компоненты;
2. какие виды ирисов лучше всего разделяются;
3. как интерпретировать PC1 и PC2 в терминах морфологии цветка.

6 Практика 4. PCA и кластеризация

6.1 PCA как шаг перед k–means

На этом этапе студенты рассматривают PCA как инструмент уменьшения размерности перед кластеризацией:

1. выполняется PCA до двух–трёх компонент;
2. проводится кластеризация методом k–средних в пространстве компонент;
3. результаты сравниваются с кластеризацией в исходном пространстве и/или с истинными метками (если они известны).

6.2 Упражнение 7 (Iris: PCA + k–means)

Задание. Для Iris:

1. выполните PCA до двух компонент;
2. запустите k–means с $k = 3$ в пространстве $(\mathrm{PC1}, \mathrm{PC2})$;
3. визуализируйте кластеры и сравните их с истинной разметкой (через матрицу ошибок).

6.3 Упражнение 8 (реальный многомерный датасет)

Задание. Выберите реальный многомерный датасет (например, промышленный, финансовый, биологический):

1. стандартизируйте признаки и выполните PCA до 2–3 компонент;
2. примените k–means с несколькими значениями k;
3. визуализируйте кластеры в пространстве первых компонент;
4. интерпретируйте кластеры через средние значения исходных признаков, сформулируйте возможные прикладные выводы.

7 Заключение

Описанные практические занятия формируют у магистрантов не только технические навыки работы с PCA, но и умение ставить и решать исследовательские задачи на реальных данных, что является ключевым шагом к подготовке публикаций в журналах первого квартиля (Q1).