

Кластерный анализ

Методы группировки данных без учителя

- 1 Введение в кластерный анализ
- 2 Расстояния и меры близости
- 3 Методы кластеризации
 - Иерархическая кластеризация
 - К-средних (K-means)
 - DBSCAN
- 4 Выбор числа кластеров
- 5 Оценка качества кластеризации
- 6 Сравнение методов
- 7 Заключение

Что такое кластерный анализ?

Определение

Кластерный анализ — это задача разбиения множества объектов на группы (кластеры) так, чтобы:

- объекты внутри одной группы были **похожи** друг на друга;
- объекты из разных групп были **различны**.

Что такое кластерный анализ?

Определение

Кластерный анализ — это задача разбиения множества объектов на группы (кластеры) так, чтобы:

- объекты внутри одной группы были **похожи** друг на друга;
- объекты из разных групп были **различны**.

Важно

Это метод **обучения без учителя** (unsupervised learning) — метки классов изначально неизвестны.

Меры расстояния между объектами

Для кластеризации необходимо задать меру близости.

Евклидово расстояние:

$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

Манхэттенское расстояние:

$$d(x, y) = \sum_{i=1}^n |x_i - y_i|$$

Меры расстояния между объектами

Для кластеризации необходимо задать меру близости.

Евклидово расстояние:

$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

Манхэттенское расстояние:

$$d(x, y) = \sum_{i=1}^n |x_i - y_i|$$

Также используют:


- Косинусное расстояние (для текстов, векторов)
- Расстояние Махаланобиса (учёт корреляций)

- **Агломеративные методы** (снизу вверх): каждый объект — отдельный кластер, затем объединяем ближайшие.
- **Дивизивные методы** (сверху вниз): все объекты в одном кластере, затем разделяем.

Иерархическая кластеризация

- **Агломеративные методы** (снизу вверх): каждый объект — отдельный кластер, затем объединяем ближайшие.
- **Дивизивные методы** (сверху вниз): все объекты в одном кластере, затем разделяем.

Результат — дендрограмма:



1. Выбрать K — количество кластеров.
2. Инициализировать центры кластеров случайно.
3. Повторять до сходимости:
 - Отнести каждую точку к ближайшему центру.
 - Пересчитать центры как среднее точек в кластере.

Метод К-средних

1. Выбрать K — количество кластеров.
2. Инициализировать центры кластеров случайно.
3. Повторять до сходимости:
 - Отнести каждую точку к ближайшему центру.
 - Пересчитать центры как среднее точек в кластере.

Плюсы

Простой, быстрый, работает для больших данных.

Минусы

Нужно задать K , чувствителен к выбросам, кластеры — только сферические.

DBSCAN (Density-Based Clustering)

Основан на плотности точек.

ϵ — радиус окрестности

minPts — минимальное число точек в окрестности для ядерной точки

DBSCAN (Density-Based Clustering)

Основан на плотности точек.

ϵ — радиус окрестности

minPts — минимальное число точек в окрестности для ядерной точки

Типы точек:

- Ядерные (core)
- Граничные (border)
- Шум (noise)

DBSCAN (Density-Based Clustering)

Основан на плотности точек.

ϵ — радиус окрестности

minPts — минимальное число точек в окрестности для ядерной точки

Типы точек:

- Ядерные (core)
- Граничные (border)
- Шум (noise)

Преимущество: находит кластеры произвольной формы, устойчив к выбросам.


Как выбрать количество кластеров?

Метод локтя (Elbow method):

- Строим график

$$SSE = \sum_{i=1}^K \sum_{x \in C_i} \|x - \mu_i\|^2$$

- Ищем точку излома




Как выбрать количество кластеров?

Метод локтя (Elbow method):

- Строим график

$$SSE = \sum_{i=1}^K \sum_{x \in C_i} \|x - \mu_i\|^2$$

- Ищем точку излома



Другие методы: **силуэт** (silhouette score), **индекс Калински-Харабаса**, **индекс Дэвиса-Болдуина**.

Силуэт (Silhouette)

Для каждой точки:

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

где $a(i)$ — среднее расстояние до точек своего кластера, $b(i)$ — до ближайшего соседнего.

Силуэт (Silhouette)


Для каждой точки:

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

где $a(i)$ — среднее расстояние до точек своего кластера, $b(i)$ — до ближайшего соседнего.

- $s(i) \approx 1$ — хорошо сгруппирована
- $s(i) \approx 0$ — на границе
- $s(i) \approx -1$ — плохо (скорее в соседний кластер)

Пример визуализации (K-means)



Сравнение методов кластеризации

Метод	Форма кластеров	Параметры	Выбросы
K-means	Сферические	K	Чувствителен
Иерархический	Любая	Порог	Средне
DBSCAN	Любая	ε , minPts	Устойчив

Сравнение методов кластеризации

Метод	Форма кластеров	Параметры	Выбросы
K-means	Сферические	K	Чувствителен
Иерархический	Любая	Порог	Средне
DBSCAN	Любая	ε , minPts	Устойчив

Что выбрать?

- Быстро и данные сферические → K-means
- Иерархия важна → иерархическая
- Шум и сложная форма → DBSCAN

- Кластерный анализ помогает находить скрытые группы в данных.
- Выбор метода зависит от формы данных, наличия шума и целей.
- Важно корректно выбирать число кластеров и интерпретировать результаты.