

Алгоритм кластеризации Хартигана-Вонга

Оптимизация классического метода k-means

Хартиган & Вонг, 1979 — “Algorithm AS 136: A K-Means Clustering Algorithm”

- 1 Постановка задачи кластеризации
- 2 Алгоритм Хартигана-Вонга
- 3 Сравнение с методом Ллойда
- 4 Пример работы
- 5 Преимущества и недостатки
- 6 Заключение

Задача кластеризации

Что такое кластеризация?

Разбиение множества объектов на группы (кластеры) так, чтобы:

- объекты **внутри** кластера были похожи друг на друга;
- объекты из **разных** кластеров отличались.

Цель k-means

Минимизировать сумму квадратов расстояний внутри кластеров (WCSS):

$$J = \sum_{j=1}^k \sum_{x \in C_j} \|x - \mu_j\|^2$$

где μ_j — центроид j -го кластера.


Проблемы классического k-means (Ллойда)

- Чувствительность к инициализации: разные начальные центры $\rightarrow$ разные результаты.
- Локальные минимумы: алгоритм может застрять в плохом решении.
- Фиксированное число кластеров k (задаётся пользователем).
- Только сферические кластеры одинакового размера.

Основная идея

Отличие от метода Ллойда:

- Не пересчитывает центроиды только после полного прохода.
- Перемещает точки **по одной**, сразу обновляя центроиды.
- Использует **эффективные вычисления изменения WCSS**.
- Гарантирует *монотонное уменьшение* целевой функции.



Theorem (Критерий перемещения)

Точку x из кластера C_i в кластер C_j выгодно переместить, если:

$$\frac{n_j}{n_j + 1} \|x - \mu_j\|^2 < \frac{n_i}{n_i - 1} \|x - \mu_i\|^2$$

- ❶ **Инициализация:** выбрать k начальных центроидов (например, случайно).
- ❷ **Локальное перераспределение:**
 - Для каждой точки проверить все кластеры.
 - Если перемещение уменьшает WCSS — переместить и обновить оба центроида.
 - Повторять цикл по точкам, пока не стабилизируется.
- ❸ **Глобальная оптимизация:**
 - После завершения локального этапа можно попробовать дополнительные обмены.
- ❹ **Критерий остановки:** ни одно перемещение не улучшает WCSS.

Реализация в R и Python

R: статическая функция

```
# lgorithm artigana- onga v R
kmeans(x, centers = 3,
       algorithm = "Hartigan-Wong"
)
```

Python:

```
from sklearn.cluster import KMeans
# KMeans ispol'zuet algorithm Lloyd
kmeans = KMeans(n_clusters=3,
               algorithm='lloyd')
```

Примечание

В современном scikit-learn Хартиган-Вонг не реализован по умолчанию. В R — это алгоритм по умолчанию для `kmeans()`.

Сравнение характеристик

Характеристика	Ллойд	Хартиган-Вонг
Тип обновления	Пакетный	Онлайн (поточечный)
Скорость на больших данных	Быстрее	Медленнее
Качество кластеров	Ниже	Выше (меньше лок. мин.)
Гарантия сходимости	Да	Да (монотонно)
Вычислительная сложность	$O(nk)$	$O(n^2k)$ в худшем случае

- Хартиган-Вонг даёт на **5–15% лучший WCSS** на сложных данных.
- Однако требует больше вычислений на каждую итерацию.

Слева — инициализация, справа — результат после работы Хартигана-Вонга

Ключевое преимущество: алгоритм может откатить плохое решение, перемещая по одной точке.

Преимущества:

- + Лучшее качество кластеризации.
- + Меньше чувствителен к инициализации.
- + Строгая монотонная сходимость.
- + Работает с разными метриками (при модификации).

Недостатки:

- Медленнее для $n > 10^5$.
- Требуется памяти $O(nk)$.
- Не подходит для потоковых данных.
- Всё ещё требует задания k .

Когда использовать?

Рекомендации

Используйте Хартигана-Вонга, если:

- Размер данных умеренный ($n \leq 50000$).
- Качество важнее скорости.
- Вы подозреваете наличие локальных минимумов.
- Работаете в R (там он по умолчанию).

Альтернативы

Для больших данных: **k-means++** + Lloyd. Для не-сферических кластеров: **DBSCAN**, **Gaussian Mixtures**.

- **Хартиган-Вонг** — это улучшенная онлайн-версия k-means.
- Основная идея: поточечное перемещение с мгновенным обновлением центроидов.
- Даёт лучшее качество, но медленнее.
- Реализован в R как алгоритм по умолчанию.
- Является **золотым стандартом** для небольших и средних наборов данных, когда нужно гарантированно хорошее разбиение.

-  Hartigan, J. A.; Wong, M. A. (1979). *Algorithm AS 136: A K-Means Clustering Algorithm*. Journal of the Royal Statistical Society. Series C (Applied Statistics), 28(1), 100–108.
-  Lloyd, S. (1982). *Least squares quantization in PCM*. IEEE Transactions on Information Theory, 28(2), 129–137.
-  Pedregosa et al. (2011). *Scikit-learn: Machine Learning in Python*. JMLR 12, 2825–2830.