

# Алгоритм инициализации Форджи (Forgy)

Классический метод выбора начальных центров для k-means

- 1 Введение
- 2 Алгоритм
- 3 Достоинства и недостатки
- 4 Сравнение с альтернативами
- 5 Заключение

# Что такое метод Форджи?

## Определение

**Метод Форджи** (Forgy's method) — один из первых и самых простых способов инициализации центроидов в алгоритме **k-means**.

- Предложен Эдвардом Форджи в 1965 году.
- Часто ошибочно называют отдельным алгоритмом кластеризации.
- Является стандартным методом в пакетах: R, MATLAB, scikit-learn (опция `init='random'` для k-means).

# Почему инициализация важна?

- k-means чувствителен к начальному положению центров.
- Неудачный старт → плохое локальное решение.
- Forgys метод — простой, но может привести к несбалансированным кластерам.

**Старт →  
Результат**

# Шаг 1: Выбор $k$ центров

## Алгоритм Форджи для инициализации:

1. Выбрать число кластеров  $k$ .
2. **Случайным образом** выбрать  $k$  точек из исходного набора данных.
3. Эти точки становятся начальными центроидами  $\{\mu_1, \mu_2, \dots, \mu_k\}$ .

**Никаких дополнительных вычислений!** Просто равномерное случайное извлечение без возвращения.

## Шаг 2: Стандартный k-means

После инициализации запускается обычный алгоритм k-means:

❶ Назначение точек к кластерам:

$$C_i^{(t)} = \{x_p : \|x_p - \mu_i^{(t)}\|^2 \leq \|x_p - \mu_j^{(t)}\|^2 \forall j\}$$

❷ Пересчёт центроидов:

$$\mu_i^{(t+1)} = \frac{1}{|C_i^{(t)}|} \sum_{x \in C_i^{(t)}} x$$

❸ Повторять до сходимости.

## Преимущества

- **Простота реализации** — одна строка кода.
- **Быстрота** —  $O(k)$  времени на инициализацию.
- **Работает для любых данных** — не требует вычисления расстояний на старте.

✓ Идеален для быстрого прототипирования.

## Недостатки

- Сильная зависимость от случайности → требуется многократный запуск.
- Может выбрать выбросы в качестве центров.
- Порождает пустые кластеры (если точка-центр оказалась изолированной).
- **Не детерминирован** — разные запуски дают разные результаты.

Для реальных задач лучше использовать k-means++ (Arthur & Vassilvitskii, 2007).



# Forgy vs k-means++ vs Random Partition

| Метод                   | Скорость | Качество | Детерминизм |
|-------------------------|----------|----------|-------------|
| Forgy (случайные точки) | ★★★      | ★★       | Нет         |
| k-means++               | ★★       | ★★★★★    | Нет         |
| Random Partition        | ★★       | ★★★★     | Нет         |

Таблица: Сравнение методов инициализации

**Рекомендация:** Для небольших данных — запустить Forgy 10+ раз, выбрать лучший WCSS.

- Метод Форджи — исторически первый способ инициализации k-means.
- Прост и быстр, но уступает в качестве более современным подходам.
- Используется в образовательных целях и для тривиальных задач.
- **Правильное название:** *Forgy's initialization*, не алгоритм кластеризации.

**Лучшая практика:** `scikit-learn: KMeans(n_clusters=k, init='random', n_init=10)`

# Вопросы для самопроверки

- ❶ Что делает метод Форджи — инициализирует центры или сразу кластеризует?
- ❷ Сколько центроидов он выбирает и как?
- ❸ Назовите два основных недостатка метода.
- ❹ Какой современный метод инициализации обычно лучше?
- ❺ Почему Forgы может привести к пустым кластерам?

-  Forgy, E. W. (1965). *Cluster analysis of multivariate data: efficiency vs. interpretability of classifications*. Biometrics, 21(3), 768–769.
-  Arthur, D., Vassilvitskii, S. (2007). *k-means++: The advantages of careful seeding*. SODA '07.
-  scikit-learn documentation: KMeans.