

Алгоритм кластеризации Ллойда

Классический k-means и его применение

Также известен как: *k-means*, итеративное проектирование (Воронеж)

- 1 Введение в кластеризацию
- 2 Алгоритм Ллойда
- 3 Математические основы
- 4 Практические аспекты
- 5 Преимущества и недостатки
- 6 Заключение

Задача кластеризации

Определение

Кластеризация — это задача **обучения без учителя** (unsupervised learning), заключающаяся в разбиении множества объектов на группы (**кластеры**) так, чтобы:

- Объекты внутри кластера были **похожи** друг на друга.
- Объекты из разных кластеров были **различны**.

Примеры применения

- Сегментация клиентов в маркетинге.
- Сжатие изображений (уменьшение цветовой палитры).
- Анализ социальных сетей (поиск сообществ).
- Обработка изображений (выделение объектов).

- Предложен **Стюартом Ллойдом** в 1957 году (опубликован в 1982).
- Самый популярный алгоритм кластеризации благодаря своей простоте и эффективности.

Definition (k-means)

Дано множество точек $X = \{x_1, \dots, x_n\} \subset \mathbb{R}^d$. Требуется разбить их на k кластеров $S = \{S_1, \dots, S_k\}$, минимизируя сумму квадратов расстояний до центров кластеров:

$$\operatorname{argmin}_S \sum_{i=1}^k \sum_{x \in S_i} \|x - \mu_i\|^2$$

где μ_i — центроид (среднее арифметическое) точек кластера S_i .

Algorithm 1 Алгоритм Ллойда (k-means)

Require: Набор точек X , количество кластеров k , макс. итераций T

Ensure: Кластеры $S_1, \dots, S_k$, центры $\mu_1, \dots, \mu_k$

1: Инициализировать центры $\mu_1, \dots, \mu_k$ случайно (или k-means++)

2: **for** $t = 1$ **to** T **do**

3: **Шаг присвоения:**

$$S_i^{(t)} = \left\{ x_p : \|x_p - \mu_i^{(t-1)}\|^2 \leq \|x_p - \mu_j^{(t-1)}\|^2 \ \forall j \right\}$$

4: **Шаг обновления:**

$$\mu_i^{(t)} = \frac{1}{|S_i^{(t)}|} \sum_{x \in S_i^{(t)}} x$$

5: **if** $\mu_i^{(t)} == \mu_i^{(t-1)} \ \forall i$ **then**


6: **break** (сходимость достигнута)

7: **end if**


8: **end for**

Визуализация шагов


1. Инициализация



2. Присвоение



3. Обновление



1. Выбираем k случайных центров.
2. Каждая точка относится к ближайшему центру (диаграмма Вороного).
3. Центры пересчитываются как среднее точек в кластере.

Повторяем шаги 2-3 до сходимости.

Функция потерь: искажение (distortion)

Definition (Искажение)

$$J = \sum_{i=1}^k \sum_{x \in S_i} \|x - \mu_i\|^2$$

Theorem (Монотонное убывание)

На каждой итерации алгоритма Ллойда значение J не возрастает:

$$J^{(t+1)} \leq J^{(t)}$$

Идея доказательства.

- Шаг присвоения: фиксируем μ , минимизируем J по S (каждая точка идёт к ближайшему центру) $\Rightarrow J$ не увеличивается.
- Шаг обновления: фиксируем S , оптимальное μ_i — это среднее точек кластера $\Rightarrow J$ не увеличивается.

Таким образом, алгоритм гарантированно сходится к локальному минимуму.


- **Время одной итерации:** $O(n \cdot k \cdot d)$
 - n — количество точек
 - k — количество кластеров
 - d — размерность пространства
- **Память:** $O(n \cdot d + k \cdot d)$
- **Количество итераций:** обычно 10–100, но может быть $2^{O(k)}$ в худшем случае

Проблема

Алгоритм может сходиться к **локальному минимуму**, зависящему от начальной инициализации.

Как выбрать k ? Метод локтя

- Построить график зависимости $J(k)$ от k .
- Найти "локоть"— точку, после которой уменьшение J резко замедляется.
- Это и есть оптимальное k .



Другие методы

- Силуэт (Silhouette score)
- Индекс Калински-Харабаса
- Информационный критерий Акаике (AIC)

Проблема инициализации: k-means++

Стандартная проблема

Плохая случайная инициализация может привести к неоптимальной кластеризации (например, пустые кластеры).

Решение: k-means++ (Arthur & Vassilvitskii, 2007)

1. Выбрать первый центр μ_1 случайно из точек.
2. Для каждой точки x вычислить $D(x)^2$ — квадрат расстояния до ближайшего центра.
3. Выбрать следующий центр случайно с вероятностью $\frac{D(x)^2}{\sum D(x)^2}$.
4. Повторять шаги 2-3, пока не выбраны все k центров.

Результат: $O(\log k)$ -приближение к оптимальному решению.


Плюсы и минусы k-means

Преимущества

- + Простота реализации
- + Быстрота работы ($O(nkd)$)
- + Легко распараллеливается
- + Всегда сходится

Недостатки

- Нужно задавать k априори
- Чувствительность к выбросам
- Только выпуклые, сферические кластеры
- Локальный минимум
- Только числовые признаки



Слева: хорошо работает. Справа: плохо работает (несферические кластеры).

- **Алгоритм Ллойда** — фундаментальный алгоритм кластеризации, основанный на минимизации суммы квадратов расстояний.
- Работает итеративно: **присвоение** → **обновление** → **сходимость**.
- Гарантированно уменьшает искажение, но может застрять в локальном минимуме.
- Для улучшения инициализации используется **k-means++**.
- Широко применяется в data mining, компьютерном зрении, биоинформатике.

-  Lloyd, S. P. (1982). *Least squares quantization in PCM*. IEEE Transactions on Information Theory.
-  MacQueen, J. (1967). *Some methods for classification and analysis of multivariate observations*.
-  Arthur, D., Vassilvitskii, S. (2007). *k-means++: The advantages of careful seeding*. SODA.
-  Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.