

Алгоритм МакКуина (K-means с последовательным обновлением)

- 1 Введение в задачу кластеризации
- 2 Алгоритм МакКуина
- 3 Сравнение с алгоритмом Ллойда
- 4 Теоретические аспекты
- 5 Заключение

Что такое кластеризация?

Задача

Разбить множество объектов $X = \{x_1, \dots, x_n\}$ на k групп (кластеров) так, чтобы:

- Объекты **внутри** кластера были похожи.
- Объекты из **разных** кластеров отличались.

Что такое кластеризация?

Задача

Разбить множество объектов $X = \{x_1, \dots, x_n\}$ на k групп (кластеров) так, чтобы:

- Объекты **внутри** кластера были похожи.
- Объекты из **разных** кластеров отличались.

Важно

Кластеризация — **обучение без учителя**. Меток классов нет.

Ллойд (стандартный)

- ❶ Инициализация центров.
- ❷ Массовое распределение точек.
- ❸ Массовый пересчёт центров.
- ❹ Повторять шаги 2-3.

Ллойд (стандартный)

- 1 Инициализация центров.
- 2 Массовое распределение точек.
- 3 Массовый пересчёт центров.
- 4 Повторять шаги 2-3.

МакКуин (онлайн)

- 1 Инициализация центров.
- 2 Выбрать одну точку.
- 3 Назначить её ближайшему центру.
- 4 Тут же обновить этот центр.
- 5 Повторять для всех точек.

Ллойд (стандартный)

- 1 Инициализация центров.
- 2 Массовое распределение точек.
- 3 Массовый пересчёт центров.
- 4 Повторять шаги 2-3.

МакКуин (онлайн)

- 1 Инициализация центров.
- 2 Выбрать одну точку.
- 3 Назначить её ближайшему центру.
- 4 Тут же обновить этот центр.
- 5 Повторять для всех точек.

Ключевое отличие

МакКуин обновляет центроид **после каждой точки**, а не после всех.

Пошаговое описание алгоритма

Вход: множество точек X , число кластеров k , число эпох T .

Выход: центры $\mu_1, \dots, \mu_k$ и метки для каждой точки.

Пошаговое описание алгоритма

Вход: множество точек X , число кластеров k , число эпох T .

Выход: центры $\mu_1, \dots, \mu_k$ и метки для каждой точки.

❶ Инициализировать центры μ_j (случайные k точек из X).

❷ **Повторить T раз (эпохи):**

❶ Перемешать порядок точек X .

❷ Для каждой точки x_i в новом порядке:

❶ Найти ближайший центр: $j^* = \arg \min_j \|x_i - \mu_j\|^2$.

❷ Обновить центр:

$$\mu_{j^*} \leftarrow \mu_{j^*} + \frac{1}{n_{j^*} + 1} \cdot (x_i - \mu_{j^*})$$

где n_{j^*} — текущее число точек в кластере j^* .

Особенности шага обновления

- Скорость обучения зависит от размера кластера.
- Формула эквивалентна точному пересчёту среднего:

$$\mu_{new} = \frac{n \cdot \mu_{old} + x_i}{n + 1}$$

Особенности шага обновления

- Скорость обучения зависит от размера кластера.
- Формула эквивалентна точному пересчёту среднего:

$$\mu_{new} = \frac{n \cdot \mu_{old} + x_i}{n + 1}$$

После обновления центр μ_{j^*} становится точным средним арифметическим всех точек, уже попавших в кластер.

Особенности шага обновления

- Скорость обучения зависит от размера кластера.
- Формула эквивалентна точному пересчёту среднего:

$$\mu_{new} = \frac{n \cdot \mu_{old} + x_i}{n + 1}$$

После обновления центр μ_{j^*} становится точным средним арифметическим всех точек, уже попавших в кластер.

Преимущество

Центры корректируются сразу после первых точек — быстрая адаптация к данным.

Схема работы (одна эпоха)

- 1 **Перемешать** данные
- 2 **Цикл** по каждой точке x_i :
 - Найти ближайший центр μ_j
 - Обновить $\mu_j = \frac{n_j \cdot \mu_j + x_i}{n_j + 1}$
 - Увеличить n_j на 1
- 3 Перейти к следующей эпохе

Принцип последовательного обновления

Начальные центры -> Точка 1 -> Обновление -> Точка 2 -> Обновление -> ... -> Точка N

МакКуин против Ллойда

Характеристика	Ллойд (пакетный)	МакКуин (последовательный)
Обновление центров	После всех точек	После каждой точки
Требования к памяти	Хранятся все данные	Минимальные
Работа в потоке	Нет	Да
Сходимость	Монотонная	Может колебаться
Зависимость от порядка	Нет	Да (нужно перемешивание)

Когда выбирать МакКуина?

Рекомендации по применению

- Данные поступают **онлайн** (последовательно)
- Память не позволяет хранить все объекты сразу
- Нужна быстрая адаптация на первых итерациях
- Объём данных слишком велик для пакетной обработки

Когда выбирать МакКуина?

Рекомендации по применению

- Данные поступают **онлайн** (последовательно)
- Память не позволяет хранить все объекты сразу
- Нужна быстрая адаптация на первых итерациях
- Объём данных слишком велик для пакетной обработки

Важно

Всегда перемешивайте данные перед каждой эпохой!

Сумма квадратов расстояний (SSE):

$$J = \sum_{j=1}^k \sum_{x \in C_j} \|x - \mu_j\|^2$$

Сумма квадратов расстояний (SSE):

$$J = \sum_{j=1}^k \sum_{x \in C_j} \|x - \mu_j\|^2$$

- МакКуин **не гарантирует** монотонное убывание J на каждом шаге
- При большом числе эпох сходится к локальному минимуму
- Результат сопоставим с пакетным K-means

Пример реализации на Python

```
def mcqueen(X, k, epochs=10):  
    n_samples = len(X)  
    idx = np.random.choice(n_samples, k, replace =  
        False)  
    mu = X[idx].copy()  
    counts = np.zeros(k)  
    for i in range(epochs):  
        shuffled = X[np.random.permutation(n_samples)]  
        dist = np.sum((mu - x) ** 2, axis = 1)  
        j = np.argmin(dist)  
        counts[j] += 1  
        eta = 1.0 / counts[j]  
        mu[j] =  
            (1 - eta) * mu[j] + eta * x  
    return mu
```

- МакКуин — это **онлайн-версия** K-means
- Позволяет обрабатывать данные **по одному объекту** за раз
- Требуется **перемешивания** данных и нескольких эпох
- Исторически важный алгоритм (1967)

- МакКуин — это **онлайн-версия** K-means
- Позволяет обрабатывать данные **по одному объекту** за раз
- Требуется **перемешивания** данных и нескольких эпох
- Исторически важный алгоритм (1967)

Литература

J. MacQueen, "Some methods for classification and analysis of multivariate observations". *Proc. 5th Berkeley Symp.*, 1967.

Сравнительная таблица

	Ллойд	МакКуин
Онлайн-режим	Нет	Да
Экономия памяти	Нет	Да
Монотонная сходимость	Да	Нет
Простота реализации	Да	Да
Потоковые данные	Нет	Да