



Министерство науки и высшего образования Российской Федерации
федеральное государственное бюджетное образовательное учреждение
высшего образования
«Самарский государственный технический университет»
(ФГБОУ ВО «СамГТУ»)

Кафедра «Высшая математика»

Кластерный анализ

название практической

Практическая работа

Выполнил студент
__1__ курса, 113М группы
Бекиш Егор Павлович

подпись

Самара, 2026 г.

Оглавление

Задания	3
ОПИСАНИЕ	4
Проведение отпуска	4
Расходы на отпуск.....	7
Заключение	11
Литература.....	12

Задания

1. При помощи кластерного анализа классифицируйте респондентов на типичные группы по особенностям проведения отпуска.
2. При помощи кластерного анализа классифицируйте респондентов на группы по планируемой сумме расходов на отпуск.

ОПИСАНИЕ

Проведение отпуска

За основу проведения отпуска были взяты переменные:

- Q1 – Какой вид отдыха скорее характерен для ваших последних отпусков? Пассивный отдых (пляж, санатории, восстановление сил).
- Q2 – Какой вид отдыха скорее характерен для ваших последних отпусков? Активный отдых (занятия спортом, экскурсии, прогулки).
- Age – Возраст.

При анализе оставшихся переменных, чтобы в дальнейшем выделить группы кластеров, было выбраны более релевантные переменные, которые в текущих могут более достоверно описать группы кластеров:

- Q6 – Какую сумму Вы планируете потратить на отдых, если соберетесь в ближайший отпуск поехать за границу?
- Q7 – Какую сумму Вы планируете потратить на отдых, если соберетесь ближайший отпуск провести в России?

При данной постановке задаче возраст отображает, какой вид отдыха выбирают молодого, среднего и пожилого возраста. Так же, дополнительные переменные будут отражать затраты на данные вид.

В качестве определения оптимального количества кластеров использовалось кросс-валидация и применялась для двух методов: К-средних, метод силуэта. Результаты выбора оптимального количества кластеров можно увидеть на рисунках 1 – 2.




Рисунок 1 – Выбор k с помощью К-средних




Рисунок 2 – Выбор k с помощью метода силуэта

Количество кластеров колоссально отличаются, поэтому в основном берут К-средних, в нашем случае это 3 кластера, но еще возьмем для проверки 4. Исходные данные представлены на рисунке 3. Относительно возраста показан вид отдыха, а также к каким группа относятся расходы.




Рисунок 3 – Исходные данные

Применяем алгоритма К-средних для разделения на 3 и 4 кластера так же, как разделяем сама модель, как показано на риске 4 – 5.




Рисунок 4 – Разделение на 3 кластера




Рисунок 5 – Разделение на 4 кластера

Как можно заметить, что для отношения возраста к активному отдыху, деление на 3 кластера показывает положительный результат, так же как и при 4 кластерах для отношения возраста к пассивному отдыху.

Расходы на отпуск

За основу проведения отпуска были взяты переменные:

- Q6 – Какую сумму Вы планируете потратить на отдых, если соберетесь в ближайший отпуск поехать за границу?
- Q7 – Какую сумму Вы планируете потратить на отдых, если соберетесь ближайший отпуск провести в России?

При анализе оставшихся переменных, чтобы в дальнейшем выделить группы кластеров, было выбраны более релевантные переменные, которые в текущих могут более достоверно описать группы кластеров:

- Age – Возраст.
- Edu – Образование.
- Income – доход на одного человека.

При данной постановке задаче отношение суммы в России и за границей хорошо покажет по отношению к возрасту, образованию и доходу насколько, например, молодой человек, который учится и не имеется полноценного

дохода, готов экономить или же наоборот тратить всю полностью в том или ином случае.

На рисунках 6 – 7 отображены оптимальное количество кластеров.




Рисунок 6 – Выбор k с помощью К-средних




Рисунок 7 – Выбор k с метода силуэта

Так же, как и в прошлой задаче количество кластеров отличаются, поэтому возьмем из К-средних, т.е. 3 кластера. На рисунке 8 отображены исходные данные.




Рисунок 8 – Исходные данные

На отображенных исходных очень заметно видно, что 3 кластера будет идеально подходить для данного отношения. На рисунке 9 будет отображено деление на возрастные, образовательные и по доходу, а также предсказания самой модели.




Рисунок 9 – Разделение на 3 кластера

Полную реализацию можно изучить на GitHub репозитории [1].

Заключение

В результате выполнения практической работы я изучил и реализовал методы кластерного анализа. Так же получилось произвести исследования по отбору данных, которые показали, что обычное применение методов без их изучения не даст хорошей оценки.

Литература

1. KMeans [Электронный ресурс] // GitHub, 2026. URL: [kmeans.py](https://github.com/kmeanspy/kmeans.py). (Дата обращения: 17.05.2026)