


КЛАСТЕРНЫЙ АНАЛИЗ

1. Откройте массив данных leisure&tourism.sav, который содержит отношение респондента к отпуску и отдыху.

2. Возьмём переменные Q6 и INCOME и представим их при помощи простой **Диаграммы рассеяния**.

- Выберите в меню «**Графики**» → «**Диаграмма рассеяния**».
- Переменную INCOME поместите в поле оси x, а переменную Q6 в поле оси y, и для обозначения наблюдения используйте переменную PROF (основное занятие респондента).
- Через кнопку «**Опции**» активируйте опцию «**Показывать график с метками наблюдений**».



- Следовательно, переменные INCOME и Q6 распадаются на различные кластеры по основному занятию респондента.

-
- Самой распространенной мерой для определения расстояния между двумя точками на плоскости, образованной координатными осями x и y , является евклидова мера:

$$\sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2}$$

- В соответствии с этой формулой расстояние между основным занятием респондента составляет:

$$\begin{aligned}\sqrt{(90 - 8)^2 + (90 - 8)^2} &= 164 \\ \sqrt{7^2 + (90 - 7)^2} &= 83,3 \\ 83,3 + 164 &= 247,3\end{aligned}$$


- К сожалению, интерпретировать картину отношений между переменными не так легко. Во-первых, структуры кластеров, если вообще таковые имеются, не так чётко разделены, особенно при наличии большого количества наблюдений. Скорее наоборот, кластеры размыты и даже проникают друг в друга. Во-вторых, как правило, кластерный анализ проводится не с двумя, а с намного большим количеством переменных.

2. Команда «Анализ» → «Классификация» → «Иерархический кластерный анализ». Без графиков, только «Протокол объединения объектов в иерархическом кластерном анализе»

Порядок агломерации (кластеров)						
Этап	Объединенный кластер		Коэффициенты	Этап первого появления кластера		Следующий этап
	Кластер 1	Кластер 2		Кластер 1	Кластер 2	
1	497	500	,000	0	0	4
2	478	499	,000	0	0	23
3	491	498	,000	0	0	10
4	22	497	,000	0	1	7
5	483	496	,000	0	0	18
6	494	495	,000	0	0	7
7	22	494	,000	4	6	16
8	460	493	,000	0	0	41
9	392	492	,000	0	0	108
10	13	491	,000	0	3	25
11	476	490	,000	0	0	25
12	261	489	,000	0	0	238
13	439	488	,000	0	0	62
14	432	487	,000	0	0	69
15	485	486	,000	0	0	16
16	22	485	,000	7	15	28
17	473	484	,000	0	0	28
18	19	483	,000	0	5	39
19	462	482	,000	0	0	39
20	480	481	,000	0	0	21

- Для определения числа кластеров - смотреть на значения коэффициентов (расстояние между двумя кластерами, определенное на основании выбранной дистанционной меры (здесь: квадрат евклидового расстояния). На том этапе, где эта мера расстояния между двумя кластерами увеличивается скачкообразно, процесс объединения в новые кластеры необходимо остановить.
- В приведенном примере — это скачок с 11,031 до 8447,426. То есть после не следует производить никаких последующих объединений.

- После определения оптимального количества кластеров – можно установить принадлежность каждого объекта определенному кластеру.
- **«Иерархический кластерный анализ» - «Статистики» – «Принадлежность к кластерам» – «Одно решение»** - желаемое количество кластеров 4.
- Информацию о принадлежности каждого наблюдения к определённому кластеру можно сохранить в новой переменной: **«Сохранить» – «Одно решение» - «4»**. Теперь для каждого наблюдения будет выводиться и информация о принадлежности к кластеру.
- **Дендрограмма** – графическое изображение объединения. Иногда она помогает визуально определить число кластеров.
- Как правило, в качестве кластерообразующих признаков не используют социально-демографические характеристики. Их используют для изучения и сравнения уже полученных кластеров.




-
- В таблице «Принадлежность к кластерам» можно увидеть разбиение наблюдений на 4 кластера.
 - Отметим, что иерархический кластерный анализ эффективен для малого количества объектов. Не годится для массивов большого объема из-за трудности агломеративного алгоритма и практической бессмысленности дендрограмм. В такой ситуации целесообразно использовать **алгоритм k-средних**.

Принадлежность к кластерам	
Наблюдение	Кластеры 4
1	1
2	2
3	1
4	1
5	2
6	1
7	2
8	2
9	2
10	2
11	2
12	2
13	3

Кластеризация к- средними

- Откройте массив данных leisure&tourism.sav
- Команда «Анализ» → «Классификация» → «Кластеризация К-средними»
- Остановимся также на 4 кластерах
- Лучше указывать больше итераций, например, 99
- Можно сохранить в качестве новых переменных номер кластера и расстояние каждого респондента от центра кластера. (команда «Сохранить»)
- Сравнение средних расстояний показывает степень однородности каждого кластера



В результате мы получаем 4 кластера, с указанием количества наблюдений, отнесенных в каждый кластер.

**Число наблюдений в каждом
кластере**

Кластеризовать	1	214,000
	2	74,000
	3	100,000
	4	112,000
Допустимо		500,000
Пропущенные		,000